

LH Nautical — Desafio de Dados

Relatório Técnico: EDA, Tratamento, Análises e Modelos

Análise de Dados

Agosto de 2026

Contents

Questão 1 — EDA (Análise Exploratória de Dados)	2
Parte 1 — Visão geral da tabela <code>orders</code>	2
Parte 2 — Análise da coluna <code>total</code>	2
Parte 3 — Interpretação e diagnóstico	2
Questão 1.1 — Código SQL	3

Questão 1 — EDA (Análise Exploratória de Dados)

Contexto: O Sr. Almir quer saber: “Posso confiar nesses dados para tomar decisões?”. Esta análise usa **apenas** a tabela `orders`, sem qualquer limpeza ou tratamento — o objetivo é observar, agregar e descrever o que existe.

Parte 1 — Visão geral da tabela `orders`

Métrica	Valor
Quantidade total de linhas	48.998
Quantidade total de colunas	13
Data mínima (<code>created_at</code>)	2020-01-01 01:19:28
Data máxima (<code>created_at</code>)	2026-12-31 23:43:09

A tabela cobre um intervalo de aproximadamente **7 anos** (2020–2026), consistente com o que foi informado no briefing da empresa.

Parte 2 — Análise da coluna `total`

Métrica	Valor (R\$)
Mínimo	32,62
Máximo	127.262,02
Média	28.704,99
Mediana	25.917,84
Desvio padrão	19.425,64

Parte 3 — Interpretação e diagnóstico

Diagnóstico geral: os dados são majoritariamente confiáveis para análises, com ressalvas pontuais que não comprometem seu uso, mas merecem atenção.

Sobre possíveis outliers em `total`: A média (R\$ 28.705) é superior à mediana (R\$ 25.918), indicando uma distribuição levemente assimétrica à direita — existem alguns pedidos de valor bem alto puxando a média para cima (o maior pedido chega a R\$ 127.262,02, quase 5x a mediana). Isso não parece ser erro de digitação ou duplicidade: são poucos pedidos de alto valor, plausíveis num negócio que vende equipamentos náuticos (itens caros, como motores e embarcações, podem gerar tickets elevados). Não foram encontrados valores negativos ou zerados em `total`, o que é um bom sinal — não há indício de erro grosseiro de lançamento.

Sobre qualidade dos dados (nulos e inconsistências): - A única coluna com valores nulos é `salesperson_id` (24.131 de 48.998 registros, ~49%). Ao investigar a causa, constatamos que **100% desses nulos correspondem a pedidos do canal `ecommerce`**

— ou seja, não é um erro de coleta, é esperado: vendas online não têm vendedor associado. Pedidos do canal pos (loja física) têm 0% de nulos nessa coluna. Portanto, isso **não é um problema de qualidade**, é uma característica estrutural do negócio. - Não há duplicidade de order_number (cada pedido tem um número único). - Os valores de subtotal, discount_amount e total são **100% coerentes** entre si (subtotal – desconto = total, sem exceção nas 48.998 linhas). - As datas created_at e placed_at são idênticas em todos os registros, sem inversões cronológicas. - A distribuição de pedidos por ano cresce de forma consistente e gradual (de 4.466 em 2020 a 10.268 em 2026), sem saltos ou quedas abruptas que sugerissem falha de coleta em algum período. - Existem 4 status de pedido (paid, confirmed, cancelled, draft) — isso é relevante: pedidos draft (2.451) e cancelled (4.847) provavelmente **não deveriam entrar em análises de receita realizada**, mas isso é uma decisão de modelagem, não um problema de qualidade do dado em si.

O dataset está pronto para análises exploratórias e de diagnóstico como esta. Porém, **para análises de receita, margem e performance de vendas (próximas etapas do desafio), será necessário um tratamento prévio leve**, especificamente: 1. Filtrar ou sinalizar corretamente os status cancelled e draft, que não representam venda efetivada; 2. Tratar salesperson_id nulo como “não aplicável” (e-commerce) em vez de dado faltante, para não distorcer análises por vendedor.

Fora esses dois pontos — que são decisões de regra de negócio, não erros — a tabela orders é estruturalmente sólida, sem inconsistências, duplicidades ou valores absurdos.

Resposta direta ao Sr. Almir: sim, os dados podem ser confiados, desde que as regras de negócio acima sejam aplicadas antes de análises de receita.

Questão 1.1 — Código SQL

```
-- Quantidade total de linhas e colunas
```

```
SELECT COUNT(*) AS total_linhas
FROM orders;
```

```
SELECT COUNT(*) AS total_colunas
FROM information_schema.columns
WHERE table_name = 'orders';
```

```
-- Intervalo de datas (created_at)
```

```
SELECT
    MIN(created_at) AS data_minima,
    MAX(created_at) AS data_maxima
FROM orders;
```

```
-- Estatísticas da coluna total
```

```
SELECT
    MIN(total) AS valor_minimo,
    MAX(total) AS valor_maximo,
    AVG(total) AS valor_medio,
    MEDIAN(total) AS mediana,
    STDDEV(total) AS desvio_padrao
```

`FROM orders;`

Observação técnica (documentação para o Gabriel): as queries acima foram executadas em ambiente DuckDB, mas a sintaxe é padrão ANSI SQL e roda sem alterações em PostgreSQL, BigQuery ou SQL Server (exceto MEDIAN, que em alguns motores precisa ser substituído por PERCENTILE_CONT(0.5) WITHIN GROUP (ORDER BY total)). Nenhum WHERE, JOIN ou filtro foi aplicado, conforme a premissa da questão de não tratar os dados nesta etapa.